



PROPOSAL TUGAS BESAR ANALISIS BIG DATA

Sains Data Institut Teknologi Sumatera 2026

Judul Tugas Besar

**Analisis dan Prediksi Indeks Kesenjangan Gender di Asia Tenggara
Menggunakan Arsitektur Medallion berbasis Apache Spark**

Identitas Mahasiswa

No	Nama Peran	NIM	Username Github
1	Fabio Banyu Cyto	123450104	fabiojanya
2	Muhammad Ridwan	123450091	MuhammadRidwan-22
3	Fathinah Nur Azizah	123450072	fathinahnazh
4	Afifah Fauziah	123450002	fzh05
5	Adisty Syawalda Ariyanto	121450136	adistyS

Tema Tugas Besar

SDG 5 - Kesenjangan Gender

Ringkasan Proposal

Ringkasan proposal (maksimum 300 kata) berisi **Urgensi, tujuan, metode, dan luaran yang dihasilkan/targetkan**

Kesenjangan gender masih menjadi tantangan utama di kawasan Asia Tenggara, ditandai dengan tingginya diskriminasi gender, rendahnya partisipasi perempuan, serta ketimpangan akses pendidikan dan kesehatan. Di sisi lain, data kesetaraan gender dari World Bank tersedia dalam skala besar sehingga membutuhkan infrastruktur big data yang scalable dan efisien untuk proses analisis. Penelitian ini bertujuan membangun sistem analitik berbasis Medallion Architecture dan Apache Spark untuk menganalisis serta memprediksi tren Gender Inequality Index (GII) di 11 negara ASEAN. Metode yang digunakan meliputi implementasi pipeline Medallion Architecture (Bronze, Silver, dan Gold Layer), pemrosesan data terdistribusi menggunakan Apache Spark, serta K-Means Clustering melalui Spark MLlib. Dataset utama berasal dari World Bank Gender Statistics dan OECD SIGI 2024 dengan rentang data tahun 2000–2023. Luaran penelitian meliputi pipeline big data berbasis Spark, hasil clustering

negara ASEAN berdasarkan profil kesetaraan gender, prediksi tren GII, serta gender equality score ranking antarnegara ASEAN.

Kata kunci

Isian 5 kata kunci yang dipisahkan dengan tanda titik koma (;)

Kata Kunci : *Big Data; Apache Spark; Medallion Architecture; Gender Inequality Index; Machine Learning*

Substansi Usulan

Petunjuk: Pengusul hanya diperkenankan mengisi di tempat yang telah disediakan (diberi warna) sesuai dengan petunjuk pengisian dan tidak diperkenankan untuk memodifikasi template menghapus setiap bagian.

A. RINGKASAN PAPER

Pilih satu paper yang paling relevan dengan proyek Anda dan tuliskan ringkasannya disini. Jangan melebihi 2 halaman untuk bagian ini.

Tabel 1. Rincian Paper yang diulas

Judul	Analyzing the impact of socioeconomic indicators on gender inequality in Sri Lanka: A machine learning-based approach
Penulis	Kularathne S, Perera A, Rathnayake N, Rathnayake U, Hoshino Y.
Jurnal	PLoS One
Tahun	2024
URL	https://pmc.ncbi.nlm.nih.gov/articles/PMC11671024/

Artikel tersebut membahas analisis hubungan delapan indikator ekonomi terhadap *Gender Inequality Index* (GII) di Sri Lanka menggunakan pendekatan machine learning. Indikator yang dianalisis meliputi GDP, GDP per kapita, pengeluaran pemerintah, pendapatan pemerintah, serta tingkat pengangguran. Penelitian ini memiliki tiga tujuan utama, yaitu:

1. Menganalisis hubungan indikator sosio-ekonomi terhadap GII.
2. Membandingkan performa berbagai algoritma machine learning dalam prediksi GII.
3. Mengidentifikasi indikator mana yang paling berpengaruh terhadap GII menggunakan Explainable AI berbasis SHAP.

Dataset yang digunakan berasal dari IMF dan World Bank dengan rentang waktu 1990–2022. Algoritma yang digunakan meliputi Decision Tree, Ensemble Bagging, Ensemble Boosting, Linear Regression, Support Vector Machine (SVM), dan Gaussian Process Regression. Evaluasi model dilakukan menggunakan metrik R-Square, RMSE, dan MAE.

Hasil penelitian menunjukkan bahwa Fine Tree Regression merupakan model terbaik dengan nilai R-Square sebesar 97,5%. Hasil SHAP menunjukkan bahwa GDP dan GDP per kapita memiliki pengaruh negatif terhadap GII, sedangkan tingkat pengangguran memiliki pengaruh positif terhadap GII. Temuan ini menunjukkan bahwa peningkatan kondisi ekonomi cenderung menurunkan ketidaksetaraan gender, sedangkan peningkatan pengangguran dapat memperburuk kondisi tersebut.

1. LATAR BELAKANG

Gambarkan konteks paper: apa motivasi dan masalah yang dikemukakan para penulis? Masalah apa yang ingin mereka selesaikan atau pengetahuan apa yang ingin mereka temukan?

Kesetaraan gender merupakan salah satu pilar utama pembangunan berkelanjutan yang dirumuskan dalam Sustainable Development Goals (SDG) nomor 5 oleh Perserikatan Bangsa-Bangsa. Pencapaian SDG 5 mencakup penjaminan akses yang setara terhadap pendidikan, layanan kesehatan, pekerjaan layak, serta representasi perempuan dalam pengambilan keputusan politik dan ekonomi. Namun demikian, kemajuan menuju kesetaraan gender secara global masih belum menunjukkan perkembangan yang memadai. Laporan OECD SIGI 2024 menyebutkan bahwa sekitar 70% perempuan di kawasan Asia Tenggara masih hidup di negara dengan tingkat diskriminasi gender tinggi atau sangat tinggi [1].

Permasalahan ketidaksetaraan gender di Asia Tenggara bersifat multidimensional dan meliputi berbagai aspek kehidupan, seperti rendahnya partisipasi perempuan dalam angkatan kerja, minimnya representasi politik perempuan, tingginya angka kematian ibu, serta masih tingginya praktik pernikahan anak di beberapa negara ASEAN. Kompleksitas tersebut menunjukkan bahwa analisis terhadap indeks kesetaraan gender tidak dapat dilakukan secara parsial.

Penelitian sebelumnya mengenai analisis hubungan indikator sosio-ekonomi terhadap Gender Inequality Index (GII) di Sri Lanka menunjukkan bahwa pendekatan machine learning mampu mengidentifikasi pola hubungan yang sulit ditangkap menggunakan metode statistik konvensional [2]. Penelitian tersebut menemukan bahwa GDP per kapita dan tingkat pengangguran memiliki korelasi kuat terhadap GII dengan model Fine Tree Regression mencapai akurasi prediksi sebesar $R^2 = 0,975$. Namun, penelitian tersebut hanya dilakukan pada satu negara dengan jumlah observasi yang terbatas sehingga belum mampu merepresentasikan dinamika kawasan Asia Tenggara secara menyeluruh.

Di sisi lain, sumber data terkait kesetaraan gender saat ini tersedia dalam skala yang sangat besar. World Bank Gender Statistics menyediakan lebih dari 900 indikator yang mencakup lebih dari 200 negara dengan rentang waktu sejak tahun 1960 hingga 2025 [3]. Volume, variasi, dan kecepatan pembaruan data tersebut memerlukan infrastruktur big data yang mampu menangani proses pengolahan data secara efisien dan scalable.

Apache Spark merupakan salah satu framework pemrosesan data terdistribusi yang mampu melakukan komputasi paralel dengan performa tinggi [4]. Selain mendukung pemrosesan data skala besar, Spark juga menyediakan library machine learning terintegrasi melalui MLlib yang mendukung proses analisis prediktif dan clustering [5].

Namun, kemampuan pemrosesan data yang cepat saja tidak cukup apabila tidak disertai dengan manajemen kualitas data yang baik. Salah satu tantangan utama dalam analisis data gender adalah tingginya missing values dan inkonsistensi antar sumber data. Untuk mengatasi permasalahan tersebut, Medallion Architecture digunakan sebagai pendekatan pengelolaan data modern yang membagi pipeline menjadi tiga lapisan, yaitu Bronze, Silver, dan Gold [6]–[8]. Pendekatan ini memungkinkan proses validasi, pembersihan, dan transformasi data dilakukan secara bertahap sehingga data yang digunakan dalam analisis menjadi lebih terstruktur dan dapat dipercaya.

Berdasarkan uraian tersebut, terdapat research gap yang cukup signifikan. Penelitian sebelumnya umumnya hanya berfokus pada satu negara, menggunakan dataset berskala kecil, serta belum mengintegrasikan arsitektur pipeline data yang scalable berbasis big data. Oleh karena itu, tugas besar ini bertujuan membangun sistem analitik end-to-end menggunakan Apache Spark dan Medallion Architecture untuk menganalisis serta memprediksi tren kesetaraan gender di 11 negara ASEAN menggunakan data World Bank Gender Statistics.

2. RINGKASAN KONTRIBUSI

Setiap paper memberikan sesuatu yang baru. Uraikan kontribusi utamanya - algoritma baru, hasil eksperimen, dataset baru, atau analisis baru

Penelitian ini memberikan kontribusi berupa pengembangan pipeline analitik berbasis Medallion Architecture menggunakan Apache Spark untuk analisis kesetaraan gender di kawasan Asia Tenggara. Berbeda dengan penelitian utama yang hanya menggunakan dataset skala kecil pada satu negara, penelitian ini memanfaatkan lebih dari 900 indikator World Bank Gender Statistics dengan cakupan 11 negara ASEAN. Selain itu, penelitian ini mengimplementasikan algoritma K-Means Clustering menggunakan Spark MLlib untuk menghasilkan analisis tren, pengelompokan negara, serta gender equality scoring secara scalable pada lingkungan big data.

3. KETERBATASAN DAN DISKUSI

Identifikasi keterbatasan metodologi atau klaim generalisasi paper ini secara kritis. Apakah keterbatasan tersebut mengubah cara Anda menilai temuan paper ini?

Paper utama yang digunakan sebagai referensi memiliki beberapa keterbatasan dibandingkan dengan topik tugas besar ini. Penelitian sebelumnya hanya berfokus pada satu negara dan belum membahas implementasi Medallion Architecture dalam analisis kesetaraan gender. Selain itu, ukuran dataset yang digunakan relatif kecil sehingga generalisasi hasil penelitian masih terbatas.

Meskipun demikian, paper tersebut tetap relevan karena berhasil menunjukkan bahwa pendekatan machine learning efektif digunakan untuk analisis Gender Inequality Index (GII). Oleh karena itu, tugas besar ini dapat dipandang sebagai pengembangan lebih lanjut dari penelitian sebelumnya melalui

perluasan cakupan wilayah, peningkatan skala data, serta penggunaan pipeline analitik berbasis Apache Spark dan Medallion Architecture.

4. MENGAPA PAPER INI?

Dari sekian banyak paper, mengapa Anda memilih ini? Apa yang menarik dari topiknya? Setelah membacanya, apakah Anda mendapat apa yang diharapkan?

Paper berjudul *Analyzing the Impact of Socioeconomic Indicators on Gender Inequality in Sri Lanka: A Machine Learning-Based Approach* dipilih karena memiliki relevansi yang tinggi dengan topik tugas besar yang diusulkan. Penelitian tersebut sama-sama membahas analisis Gender Inequality Index (GII) menggunakan pendekatan machine learning sehingga dapat dijadikan dasar konseptual dalam pengembangan sistem analitik yang lebih besar.

Selain itu, hingga saat ini masih sangat sedikit penelitian yang menggabungkan Medallion Architecture dengan topik kesetaraan gender dalam konteks big data. Oleh karena itu, penelitian ini mengombinasikan beberapa referensi berdasarkan kebutuhan teknis dan kesesuaian topik.

Secara umum, referensi yang digunakan terbagi ke dalam beberapa kategori berikut:

1. Arsitektur & Infrastruktur Big Data [6]-[8]
2. Apache Spark dan MLlib [4], [5], [9]
3. Kafka & Streaming Processing [10]–[13]
4. Hadoop HDFS [14], [15]
5. K-Means Clustering [16], [17]
6. Gender Equality dan SDG 5 [1]–[3], [18]–[20]

Penelitian ini pada dasarnya merupakan pengembangan dari paper utama dengan dua perbedaan utama, yaitu perluasan cakupan wilayah dari satu negara menjadi 11 negara ASEAN serta penggunaan pipeline modern berbasis Medallion Architecture dan Apache Spark.

5. KONTEKS RISET YANG LEBIH LUAS

Hubungkan paper ini dengan tema-tema besar dalam Big Data: pemrosesan terdistribusi, manajemen kualitas data, skalabilitas, analitik real-time vs. batch, atau kesiapan data untuk machine learning. Apakah metode ini berpotensi diterapkan ke domain lain?

Penelitian ini menghubungkan analisis kesetaraan gender dengan tema besar dalam ekosistem big data.

1. Pemrosesan Terdistribusi

Penggunaan Apache Spark sebagai engine utama menempatkan penelitian ini dalam paradigma pemrosesan terdistribusi modern. Spark mampu mengatasi keterbatasan MapReduce melalui komputasi in-memory sehingga pemrosesan data menjadi lebih cepat dan efisien [4].

2. Manajemen Kualitas Data

Data gender memiliki tantangan berupa missing values dan inkonsistensi antar sumber data. Medallion Architecture digunakan untuk mengatasi masalah tersebut melalui pendekatan bertingkat Bronze, Silver, dan Gold sehingga kualitas data meningkat secara progresif [6]–[8].

3. Skalabilitas

Penelitian sebelumnya hanya menggunakan 33 observasi dari satu negara [2]. Penelitian ini meningkatkan skala analisis menjadi 11 negara ASEAN dengan rentang data selama 23 tahun dan ratusan indikator..

4. Analitik Batch vs. Real-Time

Sistem yang dibangun beroperasi pada mode batch processing karena data gender bersifat tahunan. Namun, arsitektur yang digunakan tetap fleksibel untuk dikembangkan menuju near real-time analytics apabila di masa depan tersedia data dengan frekuensi pembaruan lebih tinggi.

5. Kesiapan Data untuk Machine Learning

Layer Gold dalam Medallion Architecture dirancang sebagai consumption-ready layer untuk kebutuhan machine learning. Hal ini memastikan bahwa model K-Means Clustering memperoleh data yang bersih, terstandarisasi, dan siap digunakan.

B. DESKRIPSI PROYEK

1. TUJUAN UTAMA

Rumuskan tujuan proyek Anda, idealnya sebagai pertanyaan ilmiah. Contoh: “Apakah arsitektur Medallion berbasis Spark dapat meningkatkan throughput pemrosesan data ekspor dibandingkan pipeline tradisional?” Jelaskan mengapa tujuan ini penting dan memungkinkan dicapai. Sebutkan tujuan sekunder (stretch goal) jika ada, dihubungkan dengan paper yang Anda pilih.

Tujuan utama proyek ini dirumuskan dalam pertanyaan ilmiah berikut:

"Apakah Medallion Architecture berbasis Apache Spark dapat membangun pipeline analitik yang *scalable* dan andal untuk menganalisis serta memprediksi tren Indeks Kesenjangan Gender (GII) di 11 negara ASEAN secara lebih komprehensif dibandingkan pendekatan analitik konvensional?"

Tujuan tersebut penting karena Asia Tenggara masih menghadapi tantangan besar terkait diskriminasi gender [1]. Selain itu, pendekatan analitik konvensional memiliki keterbatasan dalam menangani data berskala besar dan pipeline yang kompleks.

Tujuan sekunder dari penelitian ini meliputi:

1. Membangun dashboard visualisasi interaktif.
2. Mengimplementasikan SHAP Values untuk interpretabilitas model.

3. Menghasilkan gender equality score ranking negara ASEAN.
4. Mengembangkan sistem analitik berbasis data lakehouse.

2. STUDI KASUS / DOMAIN APLIKASI

Domain apa yang menjadi fokus proyek Anda? Berikan contoh konkret: apa input datanya dan apa output analitik yang diharapkan? Jika sudah dijelaskan dalam ringkasan paper, maka buat lebih detail disini.

Penelitian ini berfokus pada domain analitik sosial-ekonomi berbasis big data untuk pemantauan Sustainable Development Goals (SDG 5) di kawasan Asia Tenggara.

Dataset yang digunakan ditunjukkan pada Tabel 2.

Tabel 2. Sumber dan Deskripsi Dataset Penelitian

Sumber Data	Format	Deskripsi
World Bank Gender Statistics	CSV / API	Mencakup 900+ indikator gender dari 200+ negara dengan rentang waktu 1960–2025.
OECD SIGI 2024	CSV	Fokus pada indikator diskriminasi gender secara institusional di kawasan ASEAN (Laporan Regional).

Data difilter pada 11 negara ASEAN (Indonesia, Malaysia, Thailand, Vietnam, Filipina, Singapura, Myanmar, Kamboja, Laos, Brunei, Timor-Leste) dengan 8 indikator utama SDG 5 dalam rentang tahun 2000-2023, meliputi:

- 1) Gender Inequality Index (GII)
- 2) Labour force participation rate (perempuan vs laki-laki)
- 3) Maternal mortality ratio
- 4) Adolescent birth rate
- 5) Share of seats in parliament (perempuan)
- 6) Population with at least secondary education (perempuan)
- 7) Female unemployment rate
- 8) GDP per capita

Proses Pipeline (Medallion):

1. Bronze Layer : Ingest raw CSV dari World Bank Gender Statistics dan OECD SIGI 2024, simpan as-is dengan metadata timestamp
2. Silver Layer : Pembersihan missing values, normalisasi format, join antar indikator dan antar sumber data (World Bank dan OECD SIGI), validasi konsistensi data antar negara
3. Gold Layer : Agregasi fitur siap analitik, feature engineering untuk ML, output tabel per negara per tahun

Output Analitik yang Diharapkan:

1. Tabel agregasi GII per negara ASEAN per tahun yang dapat di kueri
2. Hasil K-Means Clustering yang mengelompokkan negara ASEAN berdasarkan profil kesetaraan gender
3. Model prediksi tren GII untuk setiap negara hingga 2030
4. Gender equality score ranking 11 negara ASEAN

3. DATASET

Sebutkan dataset yang akan digunakan (sumber, ukuran, format). Jelaskan pra pemrosesan yang direncanakan. Jika mengumpulkan data sendiri, jelaskan caranya dan estimasi waktu yang diperlukan.

Penelitian ini menggunakan tiga dataset utama berbentuk tabular relasional yang berasal dari World Bank Gender Statistics [3]. Seluruh dataset berformat CSV dan terdiri atas:

1. Dataset Negara (Country Metadata): Berisi ratusan baris data mengenai profil negara, mencakup kode unik negara, nama lengkap, wilayah geografis (region), kelompok tingkat pendapatan (income group), serta atribut administratif lainnya.\
2. Dataset Indikator (Series Metadata): Berisi daftar indikator statistik yang mencakup topik analisis, nama indikator, definisi singkat dan panjang, unit pengukuran (misalnya persentase atau angka absolut), dan metode agregasi.
3. Dataset Relasi (Country-Series): Berisi pemetaan yang menghubungkan kode negara dengan kode indikator tertentu, yang memuat catatan khusus, pengecualian, atau deskripsi spesifik terkait data pada persilangan tersebut.

Untuk memastikan kualitas dan integritas data sebelum dianalisis, akan dilakukan tahapan pra pemrosesan berikut:

1. Pembersihan Data (Data Cleaning): Mengidentifikasi dan menangani missing values (nilai kosong/NaN). Kolom yang memiliki persentase nilai kosong terlalu tinggi atau tidak relevan dengan tujuan analisis akan dihapus (drop).
2. Integrasi Data (Data Merging): Menggabungkan ketiga file CSV yang terpisah ini menjadi satu dataframe yang utuh. Penggabungan akan dilakukan berdasarkan primary key (kolom kunci) yang sama, yaitu Country Code dan Series Code.
3. Seleksi Fitur (Feature Selection): Menyaring dan hanya mempertahankan kolom-kolom yang esensial untuk analisis utama (seperti Region, Income Group, Topic, Indicator Name, dan Description). Kolom teknis yang tidak diperlukan untuk ditarik insight-nya akan dihilangkan.
4. Standardisasi Teks: Menyeragamkan format tipe data, serta membersihkan karakter-karakter aneh (noise) atau spasi ganda pada kolom teks panjang (Long definition/Description) agar mudah dibaca atau diproses lebih lanjut.

4. ARSITEKTUR DAN TEKNOLOGI

Jelaskan komponen teknis utama yang akan digunakan dan bagaimana mereka berinteraksi. Jika menggunakan Medallion Architecture, jelaskan setiap lapisannya. Tunjukkan mana yang diimplementasikan sendiri dan mana yang menggunakan konfigurasi yang sudah ada.

Sistem analisis ini dirancang menggunakan infrastruktur Big Data terdistribusi yang mengintegrasikan berbagai teknologi open-source untuk menangani beban data berskala besar secara efisien. Inti dari ekosistem ini adalah Apache Spark sebagai mesin pemrosesan utama yang berinteraksi secara dinamis dengan komponen lainnya. Alur kerja dimulai dari tahap ingestion di mana data mentah dikirimkan melalui Apache Kafka yang digunakan sebagai message broker untuk proses ingestion data streaming [10], [11]. Data kemudian disimpan pada Hadoop HDFS sebagai distributed storage sebelum diproses menggunakan Apache Spark [4]. Hasil analitik akhir disimpan pada Apache Hive untuk mendukung proses query dan visualisasi.

Dalam mengelola siklus hidup data, proyek ini menerapkan Arsitektur Medallion yang membagi pemrosesan ke dalam tiga lapisan logis untuk menjamin kualitas data yang dihasilkan. Lapisan pertama adalah Bronze Layer (Raw Ingestion). Pada tahap ini, sistem menggunakan Spark Structured Streaming untuk mengambil aliran data langsung dari topik Kafka. Data disimpan apa adanya dalam format Parquet di HDFS untuk mempertahankan integritas informasi aslinya. Penggunaan partisi berdasarkan kode negara dan tahun pada tahap ini bertujuan untuk mengoptimalkan performa pembacaan data di tahap selanjutnya.

Berlanjut ke lapisan kedua, yaitu Silver Layer (Cleaning & Enrichment), data mengalami proses transformasi yang lebih intensif. Di sini, Spark Batch Processing digunakan untuk membersihkan data dari nilai yang hilang (null) serta mendeteksi dan menangani outlier. Selain pembersihan, dilakukan pengayaan data (enrichment) dengan menggabungkan metadata negara seperti pengelompokan pendapatan dan wilayah. Proses normalisasi Min-Max juga diterapkan pada indikator SDG 5 untuk memastikan skala data yang seragam, serta dilakukan penerjemahan label ke dalam Bahasa Indonesia agar informasi lebih mudah dipahami oleh pemangku kepentingan lokal.

Lapisan terakhir adalah Gold Layer (Analytics & ML). Ini merupakan tingkat kematangan data tertinggi di mana informasi sudah siap dikonsumsi untuk pengambilan keputusan. Pada lapisan ini, Spark SQL digunakan untuk membentuk tabel ringkasan dan analisis tren historis. Selain itu, pustaka Spark MLlib diimplementasikan untuk melakukan klastering negara-negara ASEAN menggunakan algoritma K-Means. Hasil akhir dari lapisan ini dipublikasikan dalam bentuk database Hive, yang mencakup berbagai views khusus seperti peringkat kesetaraan gender di ASEAN dan kemajuan spesifik Indonesia.

Secara teknis, proyek ini menggunakan perpaduan antara konfigurasi infrastruktur standar dan pengembangan logika khusus. Komponen utama yang menjadi fondasi sistem meliputi Apache Kafka versi 7.5.0, Apache Hadoop 3.2.1, dan Apache Spark 3.4.

Bagian yang diimplementasikan secara mandiri oleh tim meliputi seluruh logika pemrosesan data, yang mencakup skrip produsen Kafka untuk simulasi streaming (`kafka_producer.py`), serta seluruh kode transformasi Spark untuk lapisan Bronze, Silver, hingga Gold. Tim juga membangun model pembelajaran mesin untuk klustering serta skrip otomatisasi pipeline (`run_pipeline.sh`) yang mengintegrasikan seluruh tahapan proses. Di sisi lain, sistem ini memanfaatkan konfigurasi yang sudah tersedia melalui penggunaan image Docker resmi untuk layanan fundamental seperti ZooKeeper, Hadoop, dan Hive, yang memungkinkan tim fokus pada pengembangan logika analisis data tanpa harus membangun infrastruktur dasar dari awal.

5. METODE PEMBANDING (BASELINE)

Metode apa yang digunakan sebagai pembanding? Misalnya: pemrosesan sekuensial tanpa distribusi, pipeline sederhana satu lapisan, atau implementasi yang telah dipublikasikan. Jelaskan apakah diimplementasikan sendiri atau diambil dari sumber lain.

Untuk mengevaluasi efektivitas dan performa dari arsitektur Big Data yang dibangun, penelitian ini menggunakan metode pemrosesan data sekuensial pada node tunggal sebagai titik acuan atau baseline. Metode pembanding ini diimplementasikan secara mandiri menggunakan skrip Python konvensional dengan pustaka Pandas untuk menangani manipulasi data tanpa adanya mekanisme komputasi terdistribusi maupun sistem pesan asynchronous seperti Kafka. Pemrosesan dilakukan dengan membaca dataset CSV secara langsung dari sistem penyimpanan lokal, melakukan pembersihan data dalam satu tahap linier, dan menghasilkan output tanpa melalui pembagian lapisan data yang terstruktur.

Penggunaan metode sekuensial ini bertujuan untuk menunjukkan kontras yang signifikan dalam hal throughput dan latensi sistem. Berdasarkan parameter evaluasi, metode baseline ini memiliki keterbatasan kapasitas pemrosesan yang diproyeksikan hanya mampu menangani sekitar 200 records per detik, dengan total waktu eksekusi end-to-end yang melebihi 10 menit untuk keseluruhan dataset. Hal ini sangat berbeda dengan target sistem utama yang menggunakan Apache Spark, dimana pemrosesan paralel diharapkan mampu mencapai throughput minimal 1.000 records per detik dan memangkas waktu proses hingga di bawah 3 menit.

Selain sebagai pembanding performa teknis, metode ini juga berfungsi untuk memvalidasi urgensi penggunaan arsitektur Medallion. Dengan membandingkan pipeline sederhana satu lapisan pada baseline terhadap struktur tiga lapis (Bronze, Silver, Gold) pada sistem utama, tim dapat mengukur sejauh mana peningkatan kualitas, integritas, dan kemudahan tata kelola data yang dihasilkan melalui

pendekatan Big Data modern. Seluruh skrip pembandingan ini dikembangkan secara khusus oleh tim agar memiliki parameter logika pembersihan yang identik dengan sistem utama, sehingga hasil perbandingan matrik evaluasi tetap objektif dan relevan.

6. EVALUASI

Tentukan minimal satu metrik kuantitatif yang jelas. Contoh metrik yang umum digunakan: throughput (baris/detik), latensi end-to-end pipeline, akurasi prediksi (RMSE/MAE untuk regresi, silhouette score untuk clustering), atau rasio kompresi penyimpanan. Sebutkan nilai acuan (baseline score) yang ada di literatur atau yang Anda targetkan.

Untuk mengukur keberhasilan sistem, evaluasi dilakukan secara kuantitatif melalui tiga metrik utama dengan membandingkan pipeline berbasis Apache Spark terhadap baseline sekuensial menggunakan Pandas. Metrik pertama adalah throughput ingesti, yaitu jumlah records yang diproses per detik, sebagaimana ditunjukkan pada Tabel 3.

Tabel 3. Matrik evaluasi yang direncanakan

Metrik	Baseline	Target
Throughput ingesti (records/dtk)	200 (sekuensial)	≥ 1.000
Latensi pipeline end-to-end	> 10 menit	≤ 3 menit
Silhouette Score clustering	0 (random)	$\geq 0,50$

Berdasarkan Tabel 2, evaluasi sistem dilakukan menggunakan tiga metrik utama yang membandingkan metode baseline dengan sistem yang dibangun. Pertama, pada throughput ingesti, metode baseline dengan pemrosesan sekuensial hanya mampu menangani sekitar 200 records per detik, sedangkan sistem berbasis Apache Spark ditargetkan mencapai minimal 1.000 records per detik melalui komputasi terdistribusi dan paralel. Kedua, pada latensi pipeline end-to-end, baseline membutuhkan waktu lebih dari 10 menit untuk menyelesaikan proses dari ingesti hingga analitik, sementara sistem utama ditargetkan mampu menyelesaikannya dalam waktu maksimal 3 menit berkat penerapan Medallion Architecture. Ketiga, Silhouette Score digunakan untuk mengevaluasi kualitas clustering negara-negara ASEAN menggunakan algoritma K-Means. Baseline bernilai 0 yang merepresentasikan pengelompokan acak, sedangkan sistem ditargetkan mencapai skor minimal 0,50, yang menunjukkan bahwa hasil clustering telah membentuk kelompok yang bermakna dan terpisah dengan baik.

7. TANTANGAN ETIS DAN RISIKO SOSIAL

Tulis satu paragraf yang membahas: (A) minimal dua tantangan etis atau risiko sosial yang spesifik untuk proyek Anda - misalnya privasi data, potensi bias dalam model prediksi yang mempengaruhi kebijakan, transparansi algoritma terhadap pemangku kepentingan, atau ketergantungan pada data yang tidak representatif - dan (B) strategi mitigasi yang spesifik dan praktis. Bagian ini dinilai berdasarkan kedalaman pemikiran.

Penelitian ini menghadapi beberapa tantangan etis dan risiko sosial. Pertama, terdapat risiko bias data dan bias model karena kualitas data antarnegara ASEAN tidak selalu konsisten. Missing values dan ketidakseimbangan data dapat menyebabkan hasil analisis menjadi kurang representatif [3], [18].

Kedua, terdapat tantangan terkait transparansi algoritma dan interpretabilitas model. Penggunaan K-Means Clustering dan proses normalisasi data dapat sulit dipahami oleh pemangku kepentingan nonteknis sehingga berpotensi menimbulkan kesalahan interpretasi hasil [5], [16].

Untuk mengatasi masalah tersebut, penelitian ini menerapkan validasi kualitas data dengan threshold completeness minimal 80%, dokumentasi preprocessing secara terbuka, serta evaluasi clustering menggunakan Silhouette Score [17]. Selain itu, seluruh tahapan pipeline pada Medallion Architecture didokumentasikan agar proses analitik dapat direproduksi dan diaudit secara transparan [6]–[8].

REFERENSI

- [1] OECD, *SIGI 2024 Regional Report for Southeast Asia*. Paris, France: OECD Publishing, 2024.
- [2] S. Kularathne, A. Perera, N. Rathnayake, U. Rathnayake, dan Y. Hoshino, “Analyzing the Impact of Socioeconomic Indicators on Gender Inequality in Sri Lanka: A Machine Learning-Based Approach,” *PLoS ONE*, vol. 19, no. 12, 2024.
- [3] World Bank, “Gender Statistics DataBank,” 2024. [Online]. Available: <https://genderdata.worldbank.org/>. [Accessed: May 13, 2026].
- [4] M. Zaharia et al., “Apache Spark: A Unified Engine for Big Data Processing,” *Communications of the ACM*, vol. 59, no. 11, pp. 56–65, Nov. 2016.
- [5] X. Meng et al., “MLlib: Machine Learning in Apache Spark,” *Journal of Machine Learning Research*, vol. 17, no. 34, pp. 1–7, 2016.
- [6] M. Armbrust, A. Ghodsi, R. Xin, dan M. Zaharia, “Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics,” in *Proc. CIDR*, 2021.
- [7] Databricks, “What is a Medallion Architecture?,” 2023. [Online]. Available: <https://www.databricks.com/glossary/medallion-architecture>. [Accessed: May 13, 2026].
- [8] P. Strengtholt, *Building Medallion Architectures: Designing with Delta Lake and Spark*. Sebastopol, CA, USA: O’Reilly Media, 2024.
- [9] Apache Spark, “Structured Streaming Programming Guide,” 2023. [Online]. Available: <https://spark.apache.org/docs/latest/structured-streaming-programming-guide.html>. [Accessed: May 13, 2026].
- [10] J. Kreps, N. Narkhede, dan J. Rao, “Kafka: A Distributed Messaging System for Log Processing,” in *Proc. NetDB Workshop*, 2011.
- [11] W. Baldominos, N. Saez, dan P. Isasi, “A Study of Apache Kafka in Big Data Stream Processing,” in *Proc. IEEE Int. Conf. Information Reuse and Integration (IRI)*, 2018.

- [12] T. Akidau et al., “The Dataflow Model: A Practical Approach to Balancing Correctness, Latency, and Cost in Massive-Scale, Unbounded, Out-of-Order Data Processing,” *Proc. VLDB Endowment*, vol. 8, no. 12, pp. 1792–1803, 2015.
- [13] A. Akanbi dan M. Masinde, “A Distributed Stream Processing Middleware Framework for Real-Time Analysis of Heterogeneous Data on Big Data Platform,” *Sensors*, vol. 20, no. 11, p. 3166, 2020.
- [14] K. Shvachko, H. Kuang, S. Radia, dan R. Chansler, “The Hadoop Distributed File System,” in *Proc. IEEE 26th Symp. Mass Storage Systems and Technologies (MSST)*, 2010.
- [15] A. Oussous, F. Z. Benjelloun, A. Ait Lahcen, dan S. Belfkih, “Big Data Technologies: A Survey,” *Journal of King Saud University – Computer and Information Sciences*, vol. 30, no. 4, pp. 431–448, 2018.
- [16] Y. Feng, J. Zou, W. Liu, dan F. Lv, “Distributed K-Means Algorithm Based on a Spark Optimization Sample,” *PLoS ONE*, vol. 19, no. 12, 2024.
- [17] Apache Spark, “MLlib Clustering Documentation,” 2023. [Online]. Available: <https://spark.apache.org/docs/latest/ml-clustering.html>. [Accessed: May 13, 2026].
- [18] E. Tschopp dan H. Salam, “Spot on SDG 5: Addressing Gender (In-)Equality Within and With AI,” dalam *Technology and Sustainable Development: The Promise and Pitfalls of Techno-Solutionism*, 2023.
- [19] M. H. Özdemir, B. L. Aylak, C. Cakiroglu, dan M. Bağcı, “Prediction of the Gender Inequality Index Based on Data-Driven Interpretable Ensemble Learning Methods,” *Socio-Economic Planning Sciences*, vol. 103, p. 102366, 2026.
- [20] M. Santos, M. Fragoso, A. Machado, dan J. Azevedo, “A Deep Learning Approach to Gender Equality: Forecasting Educational Indicators with 1D-CNN Aligned with SDG 5,” *PLoS ONE*, 2025.